

# Observation multitâche à l'aide d'images satellitaires et d'éviers de cuisine (MOSAIKS)

---

Togo Data Lab Training - UCSB, CEGA, &  
emLab Février 2025

Tamma Carleton (UC Berkeley & emLab)  
en collaboration avec : Jonathan Proctor, Trinetta Chong, Taryn Fransen, Simon Greenhill,  
Jessica Katz, Hikari Murayama, Luke Sherman, Jeanette Tseng, Hannah Druckenmiller,  
Solomon Hsiang

# Un ensemble croissant de mesures depuis l'espace

Science

HOME > SCIENCE > VOL. 371, NO. 1632 > USING SATELLITE IMAGERY TO UNDERSTAND AND PROMOTE SUSTAINABLE DEVELOPMENT

Current issue First release papers Archive About Submit manuscript

REVIEW

f X in d %

## Using satellite imagery to understand and promote sustainable development

ESSAOUAII, RABIA  AND MARZOUGUI, AFEF  AND SANKARAN, SINDHUJA  Authors & Affiliations

SCIENCE • 7 AUGUST 2021 • VOL 371, ISSUE 6520 • DOI:10.1126/science.abb526

16,838 99 47



Coastal Engineering

Volume 174, June 2022, 104102



## Multispectral satellite imagery and machine learning for the extraction of shoreline indicators

Emma McAllister<sup>a</sup>  Andres Payo<sup>b</sup> Alessandro Novellino<sup>b</sup> Tony Dolphin<sup>c</sup>, Encarni Medina-Lopez<sup>a</sup>



Computers and Electronics in Agriculture

Volume 175, August 2020, 105584

## High-resolution satellite imagery applications in crop phenotyping: An overview

Chongyuan Zhang, Afef Marzougui, Sindhuja Sankaran  

Open Access Review

## Forest Biodiversity Monitoring Based on Remotely Sensed Spectral Diversity—A Review

by Patrick Kacic<sup>1,\*</sup>  and Claudia Kuenzer<sup>1,2</sup>

<sup>1</sup> Department of Remote Sensing, Institute of Geography and Geology, University of Wuerzburg, 97074 Wuerzburg, Germany

<sup>2</sup> German Remote Sensing Data Center (DFD), Earth Observation Center (EDC), German Aerospace Center (DLR), 82234 Wessling, Germany

\* Author to whom correspondence should be addressed.

Remote Sens. **2022**, *14*(21), 5363; <https://doi.org/10.3390/rs14215363>

## Un ensemble croissant de mesures depuis l'espace

Chaque système de mesure ou de contrôle est coûteux à mettre en œuvre dans la pratique.

# Un ensemble croissant de mesures depuis l'espace

Chaque système de mesure ou de contrôle est coûteux à mettre en œuvre dans la pratique.



Source : Farmonaut

Pour quels résultats, dans quels lieux et pour quelles populations devrions-nous investir ?  
la surveillance par satellite ?

# Évaluation des prévisions basées sur les satellites pour plus de 100variables

## Que peut-on voir depuis l'espace ?

- Les prédictions existantes en matière d'imagerie satellitaire et d'apprentissage automatique (SIML) sont personnalisées et hétérogènes.
- Cela limite notre capacité à évaluer ce qui peut ou ne peut pas être contrôlé à l'aide de cette nouvelle technologie

# Évaluation des prévisions basées sur les satellites pour plus de 100 variables

Que peut-on voir depuis l'espace ?

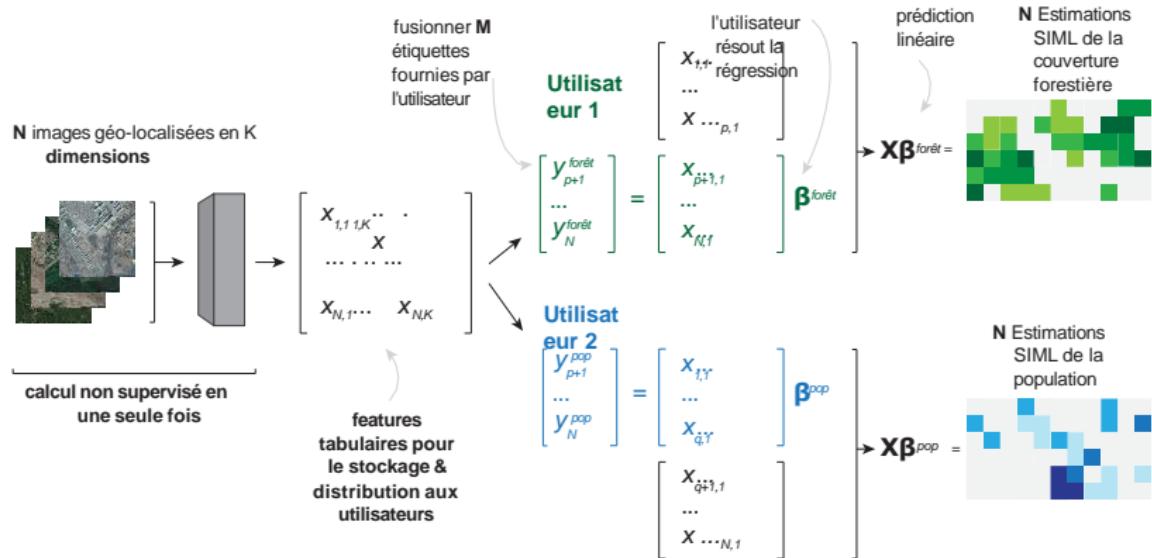
- Les prédictions existantes en matière d'imagerie satellitaire et d'apprentissage automatique (SIML) sont personnalisées et hétérogènes.
- Cela limite notre capacité à évaluer ce qui peut ou ne peut pas être contrôlé à l'aide de cette nouvelle technologie

Dans ce document, nous :

- Rassembler des données de base pour 115 résultats à l'échelle nationale et mondiale
- Construire un pipeline flexible pour produire en masse des cartes/prédictions MOSAIKS
- Examiner systématiquement les catégories de variables, les lieux géographiques et les populations qui se prêtent le mieux à une surveillance basée sur le SIML.
- Distribuer les cartes 115 et les couches de qualité des données associées

# Rappel : Pipeline MOSAIKS

## Observation multitâche à l'aide de l'imagerie satellitaire et des éviers de cuisine



[Rolf, Proctor, Carleton, Bolliger, Shankar, Ishihara, Recht, & Hsiang \(2021\)](#)

# Extension des pipelines

Pipeline original MOSAIKS

7 tâches

Échantillonnage creux

Etiquetage manuelle des données

Code de réPLICATION disponible

# Extension des pipelines

Pipeline original MOSAIKS	→	Ce travail
7 tâches	→	115 tâches
Échantillonnage creux	→	Échantillonnage dense
Etiquetage manuelle des données	→	Manipulation automatisée des variables
Code de réPLICATION disponible	→	Pipeline interactif et ressources

## Quelles sont les limites d'un pipeline de cartographie planétaire ?

Pour quels types de variables fonctionne-t-il ?  
Que pouvons-nous apprendre sur les promesses de l'imagerie satellitaire ?

# Aperçu

---

Méthodes

Résultats

Résumé

# Aperçu

---

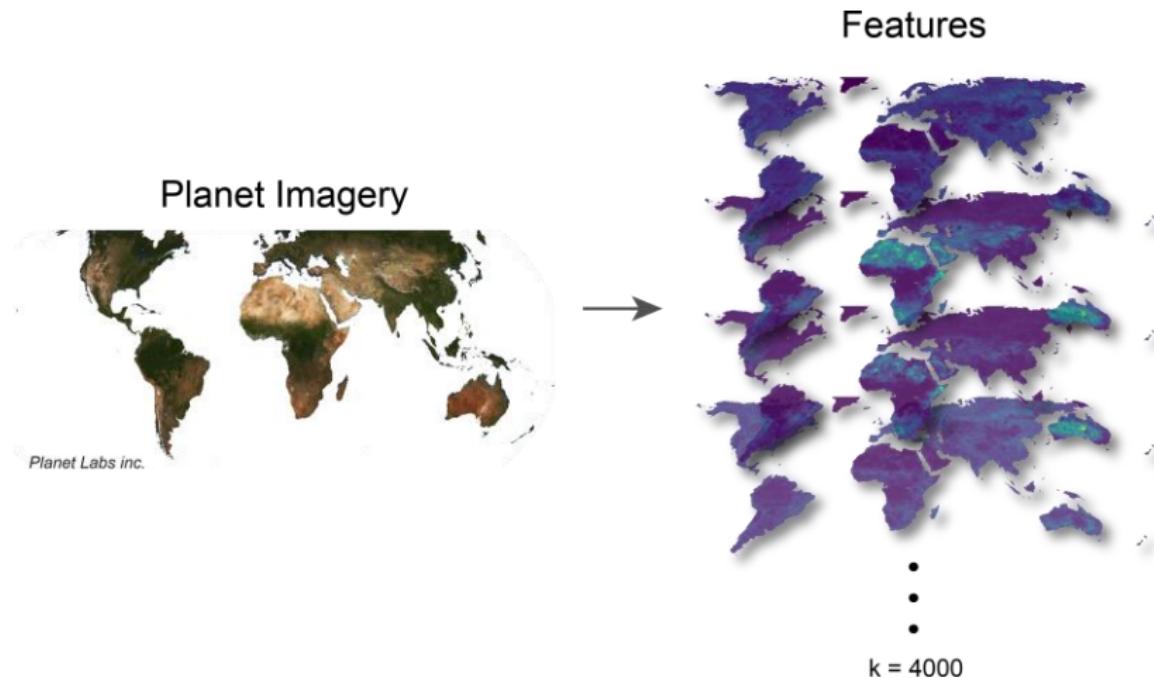
[Méthodes](#)

[Résultats](#)

[Résumé](#)

# Extraction de features en une seule fois

Features convolutionnelles aléatoires (Rahimi & Recht (2007, 2008a,b))



détails

# Spécification automatisée du modèle

$$y_I = X\beta_I + \epsilon_I$$

# Spécification automatisée du modèle

$$y_I = X\beta_I + \epsilon_I$$

Nous testons automatiquement les variations de la régression ridge  
pour trouver la spécification optimale

**Transformation:** Log ou niveaux ?

**Intercept dans la regression:** oui ou non ?

**Utilisation d'un modèle régional:** oui ou non ?

**Si polygone, utilisation des poids:** surface ou population ?

Nous rassemblons des données accessibles au public avec une diversité de structure spatiales et de catégories

# Collecte de données

Nous rassemblons des données accessibles au public avec une diversité de structure spatiales et de catégories

Catégorie	Nombre d'étiquettes	Exemple d'étiquette
Actifs agricoles	5	Propriété des terres agricoles
Agriculture	16	Rendement du maïs
Infrastructures construites	9	Bâtiments

# Collecte de données

Nous rassemblons des données accessibles au public avec une diversité de structure spatiales et de catégories

Catégorie	Nombre d'étiquettes	Exemple d'étiquette
Actifs agricoles	5	Propriété des terres agricoles

# Collecte de données

Nous rassemblons des données accessibles au public avec une diversité de structures spatiales et de catégories.

Catégorie	Nombre d'étiquettes	Exemple d'étiquette
Actifs agricoles	5	Propriété des terres agricoles
Agriculture	16	Rendement du maïs
Infrastructures construites	9	Bâtiments
Données démographiques	5	Âge médian
L'éducation	10	Années de scolarisation attendues
Santé	15	Le paludisme chez les enfants
Actifs des ménages	21	Téléphones mobiles
Revenu	9	Indice de développement humain
Systèmes naturels	8	Couverture des arbres
Occupation	17	Chômage

Méthodes

Résultats

Résumé

# Performance des pipelines

---

Les étiquettes qui... ont déjà fait l'objet d'une télédétection	56
ont déjà fait l'objet d'une télédétection avec covariables	11
n'ont jamais fait l'objet d'une télédétection	48
Total des étiquettes	115

---

# Performance des pipelines

---

Des étiquettes ont déjà fait l'objet d'une télédétection qui...	56
ont déjà fait l'objet d'une télédétection, avec des covariables	11
<u>n'ont jamais</u> fait l'objet d'une télédétection	48
Total des étiquettes	115

---

Temps de formation pour une étiquette  
Exécution avec autotuning : 20 heures de CPU

# Performance des pipelines

---

Des étiquettes ont déjà fait l'objet d'une télédétection qui...	56
ont déjà fait l'objet d'une télédétection, avec des covariables	11
<u>n'ont jamais</u> fait l'objet d'une télédétection	48
<b>Total des étiquettes</b>	<b>115</b>

---

Temps de formation pour une étiquette

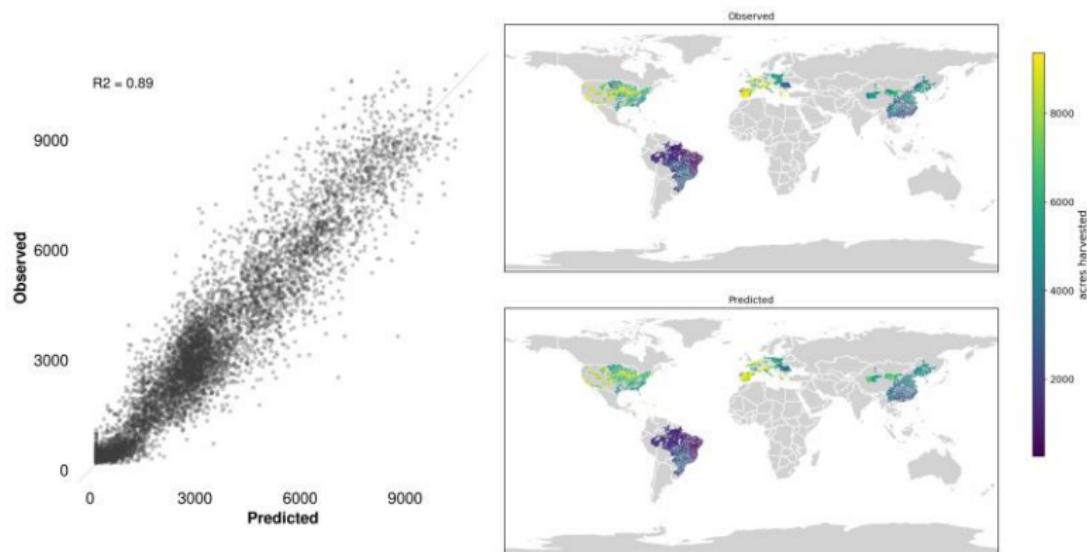
Exécution avec autotuning : 20 heures CPU

Exécution du modèle final : 2 minutes sur ordinateur portable

# Rendement du maïs

Source : [Proctor \(2021\)](#)

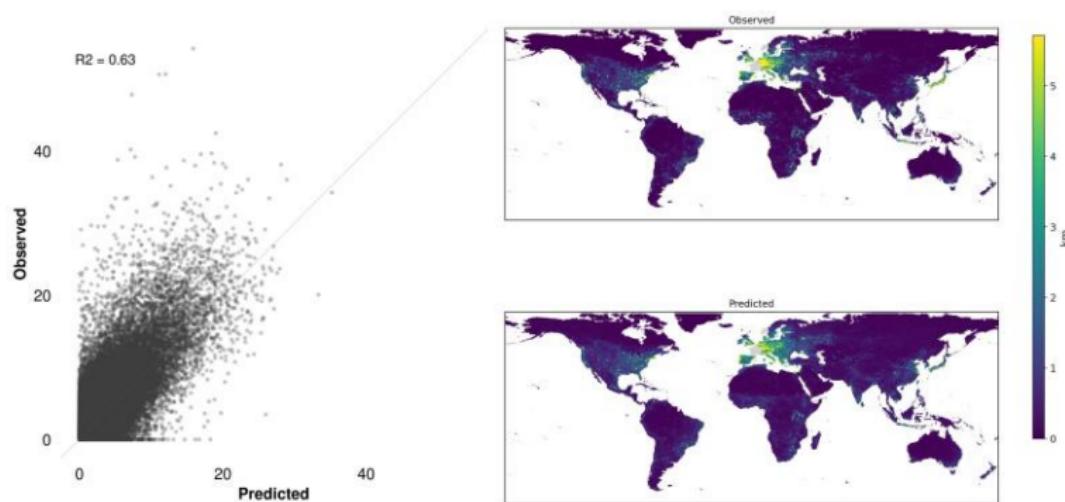
Description : Quantité de maïs récolté en acres



# Longueur de la route

Source : Open Street Maps

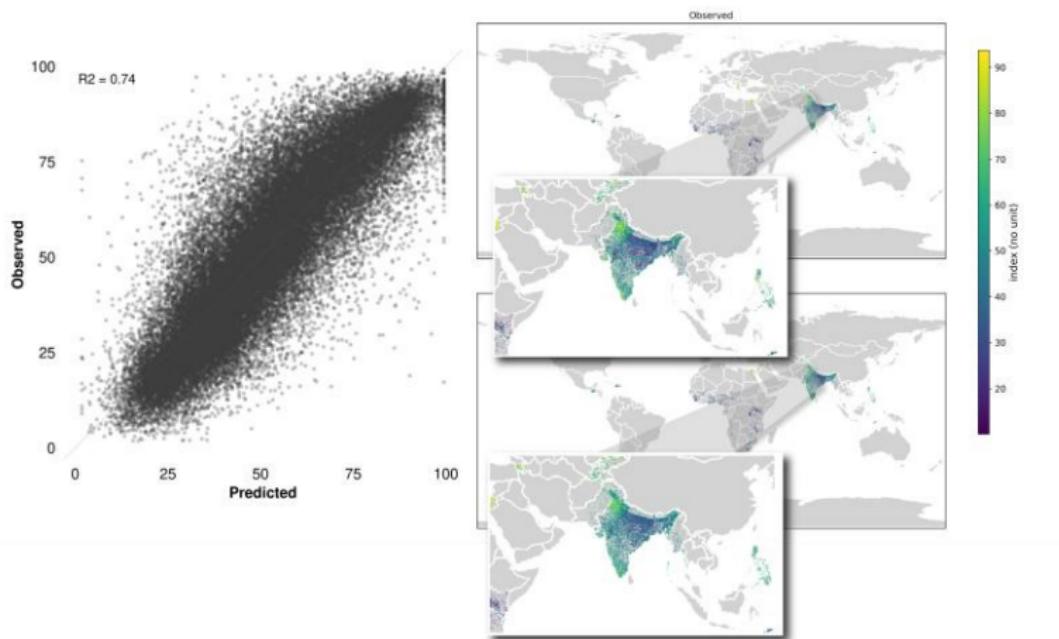
Description : Longueur des routes en kilomètres



# Indice de richesse internationale

Source : Enquêtes démographiques et de santé : Enquêtes démographiques et de santé

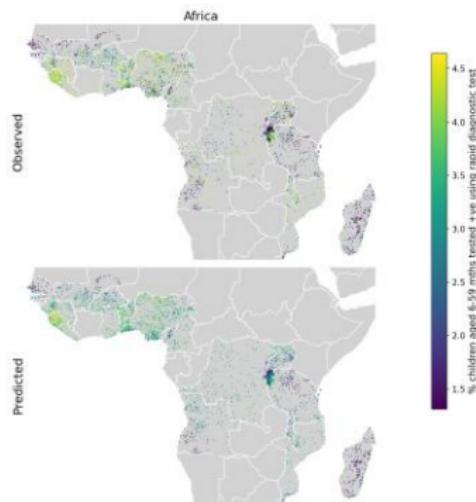
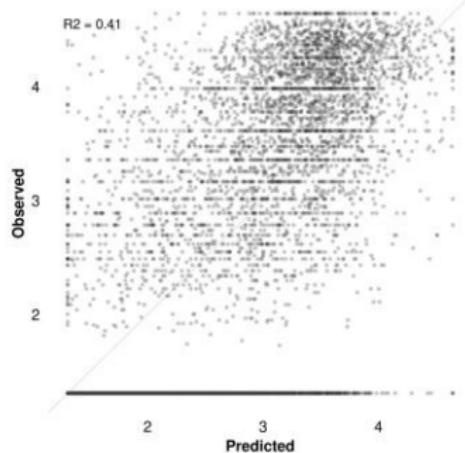
Description : Indice de richesse internationale (IWI) moyen pour chaque grappe de l'EDS



# Cas de paludisme chez les enfants

Source : Enquêtes démographiques et de santé : Enquêtes démographiques et de santé

Description : Pourcentage d'enfants âgés de 6 à 59 mois testés à l'aide d'un test de diagnostic rapide (TDR) qui sont positifs pour le paludisme



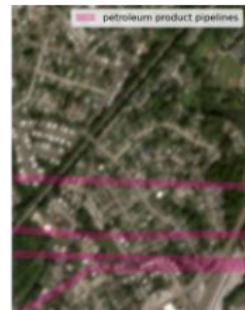
# Oléoducs et gazoducs

Source : Administration de l'information sur l'énergie

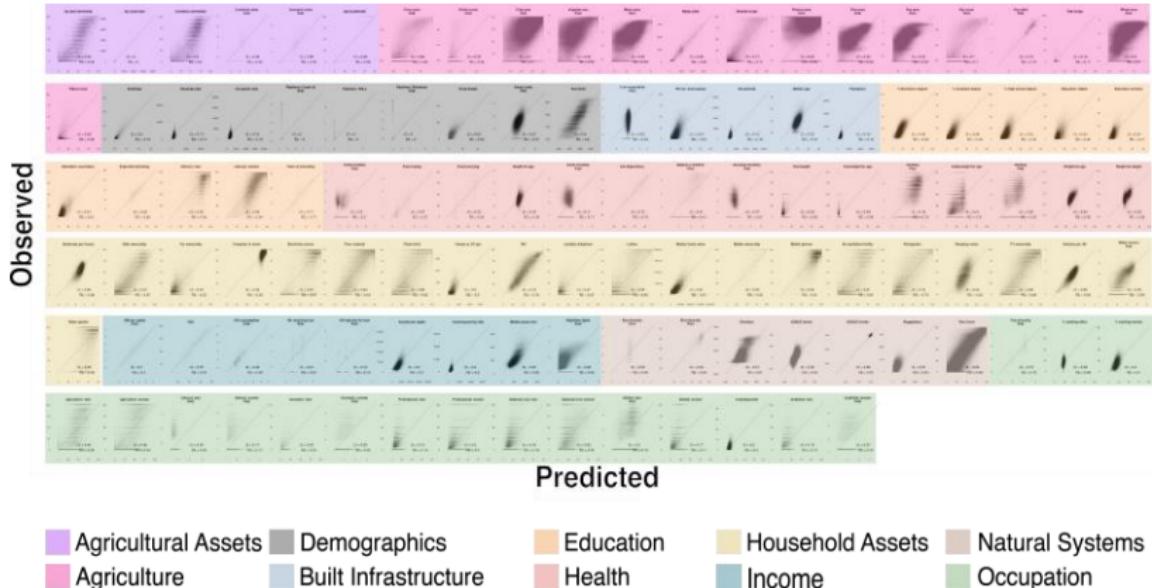
Description : Longueur des principaux oléoducs en kilomètres



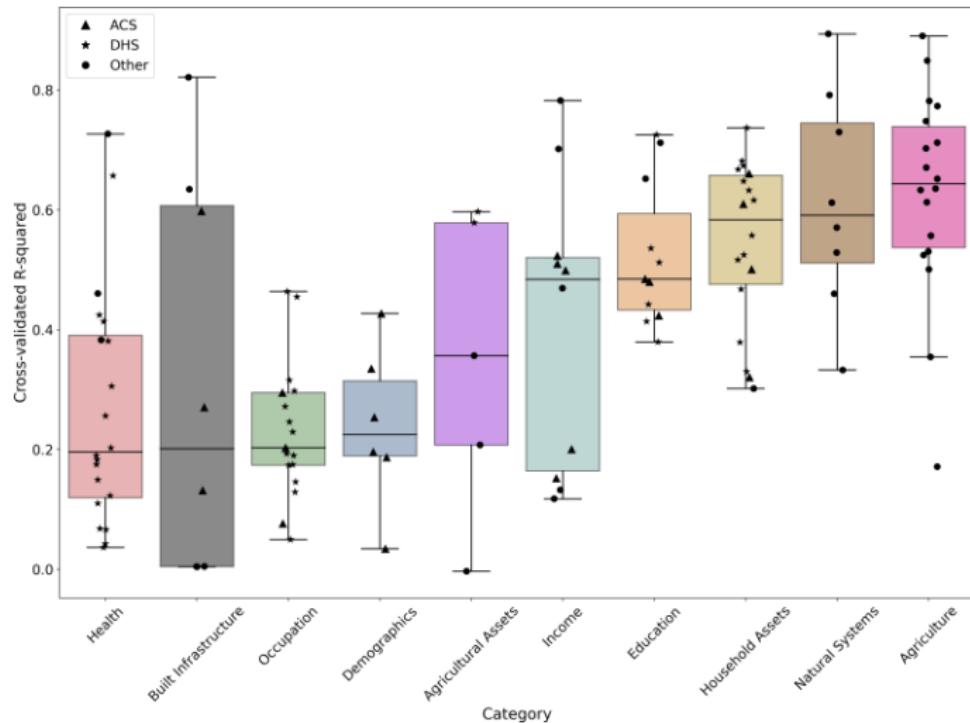
# Pipelines non visibles sur les images



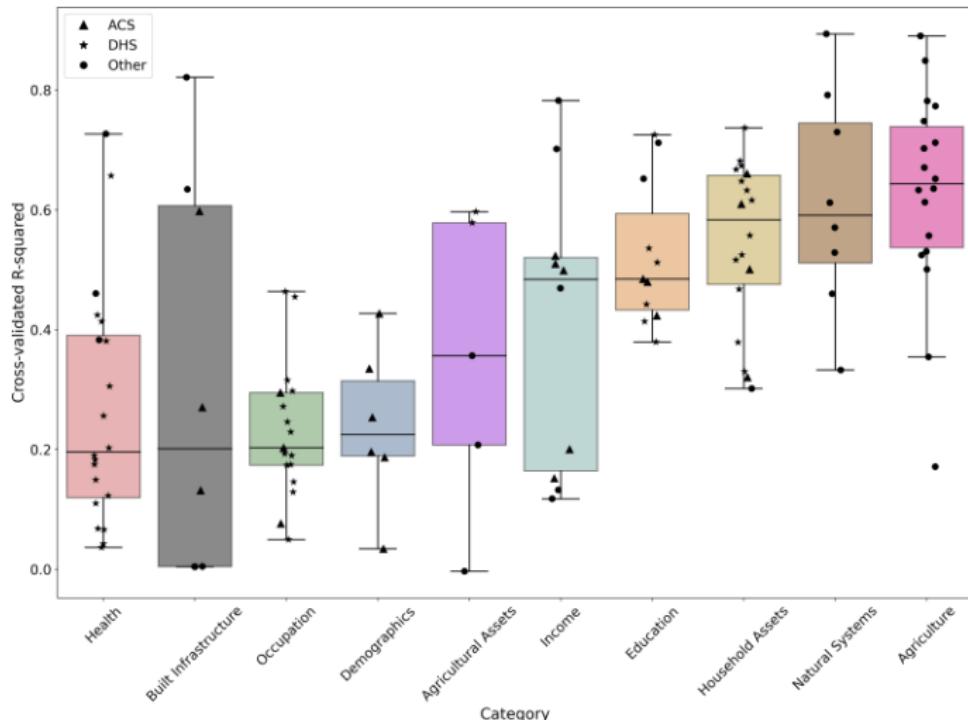
# Performance sur l'ensemble des labels



Quelles sont les catégories d'étiquettes qui se prêtent au SIML ?

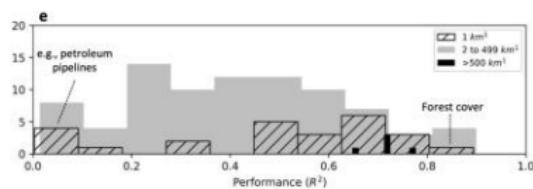
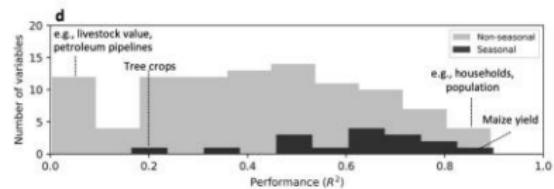
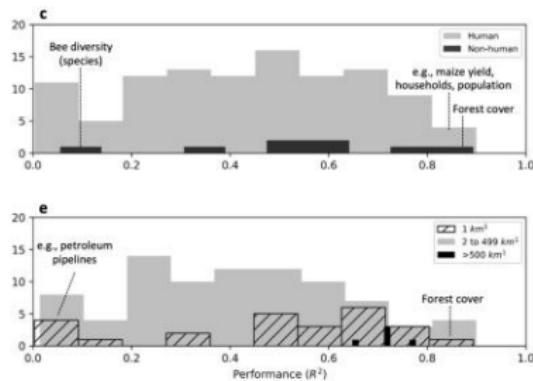
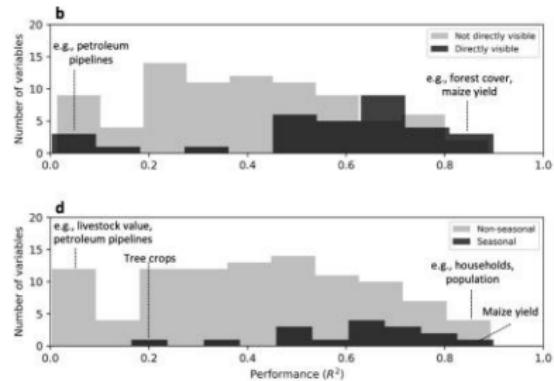


# Quelles sont les catégories d'étiquettes qui se prêtent au SIML ?

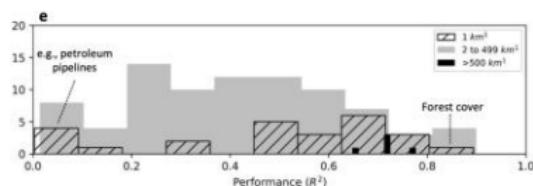
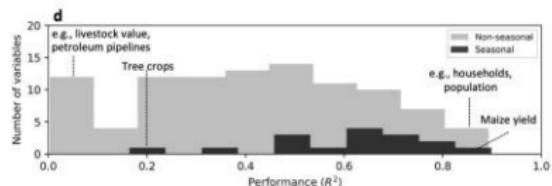
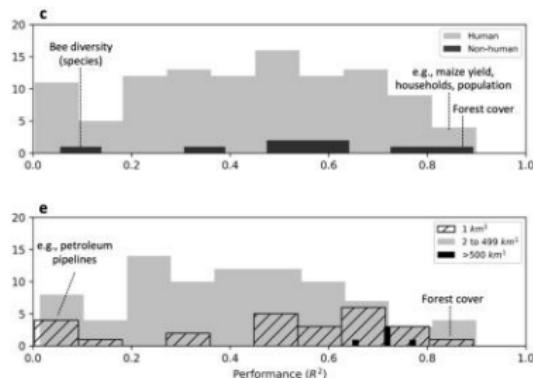
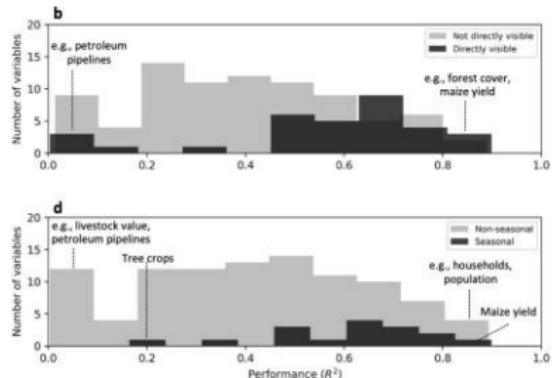


- Les performances varient considérablement d'une catégorie à l'autre, mais surtout au sein d'une même catégorie :  $\sigma_{within} = 0,19$  et  $\sigma_{across} = 0,12$ .

# Quelles sont les catégories d'étiquettes qui se prêtent au SIML ?



# Quelles sont les catégories d'étiquettes qui se prêtent au SIML ?



- Directement visible contre émergent : différence dans le  $R$  moyen<sup>2</sup> = 0,18 ( $p < 0,001$ )
- Cycle saisonnier clair ou non : différence dans la moyenne  $R^2$  = 0,19 ( $p < 0,05$ )
- Systèmes humains contre systèmes naturels : différence dans la moyenne de  $R^2$  = 0,1 ( $p = 0,23$ )
- Résolution spatiale des données de terrain : toutes les différences de moyenne  $p > 0,1$ .

# Où les mesures du SIML sont-elles fiables ?

Mean Absolute Normalized Error

$$\text{MANE}_i = \frac{1}{|L_i|} \sum_{l \in L_i} \left| \frac{\hat{\varepsilon}_{li} - \bar{\hat{\varepsilon}}_l}{\sigma(\hat{\varepsilon}_{li})} \right|$$

- $\hat{\varepsilon}_i$ : résidu du pixel  $i$  de l'étiquette  $l$
- $\bar{\hat{\varepsilon}}_l$ : moyenne des résidus pour l'étiquette  $l$
- $\sigma(\hat{\varepsilon}_{li})$ : écart-type pour les résidus de l'étiquette  $l$  dans le pixel  $i$
- $L_i$ : l'ensemble des étiquettes que nous avons dans le pixel  $i$

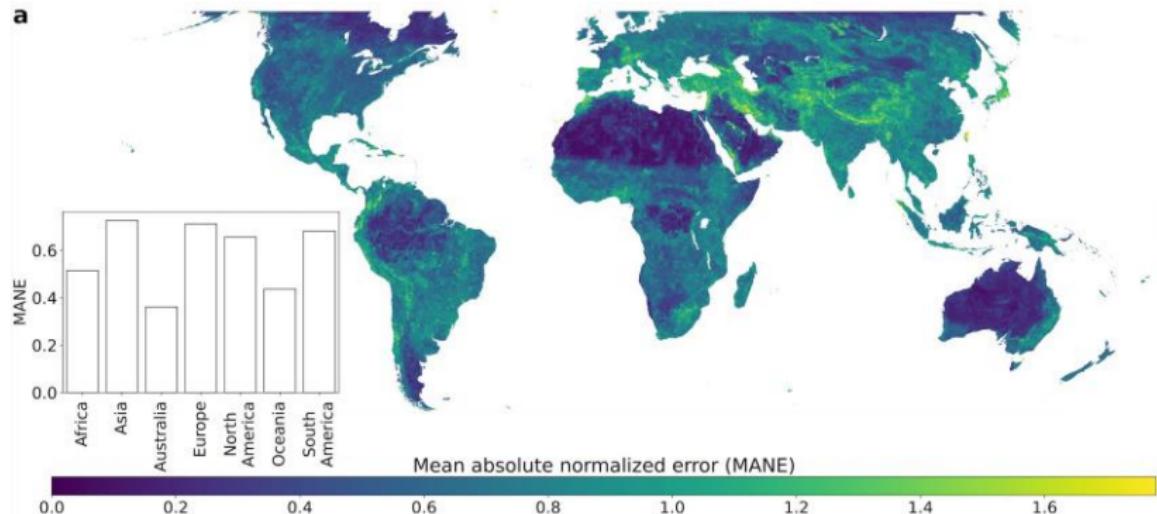
# Où les mesures du SIML sont-elles fiables ?

Mean Absolute Normalized Error

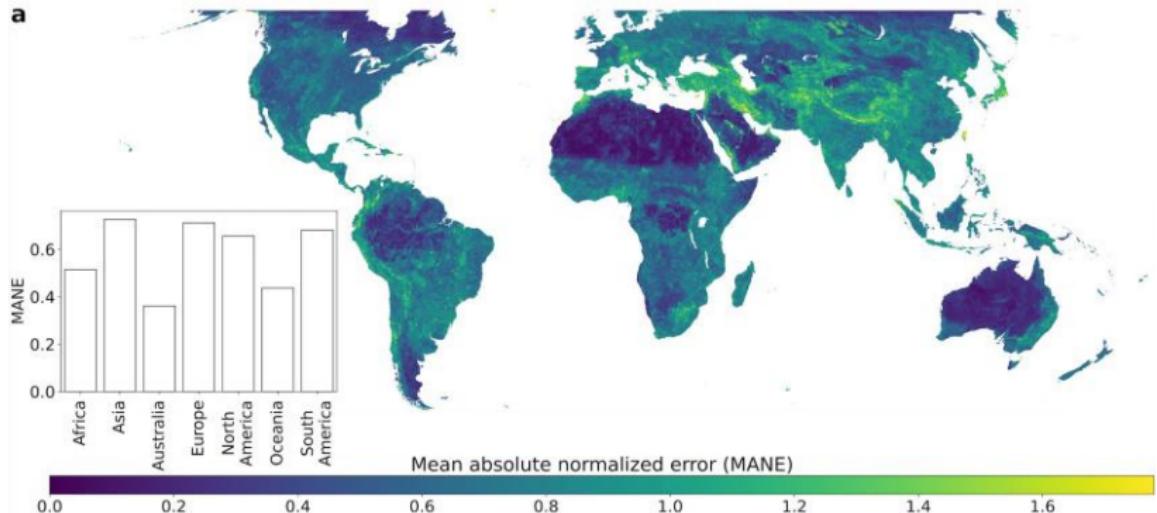
$$\text{MANE}_i = \frac{1}{|L_i|} \sum_{l \in L_i} \left| \frac{\hat{\varepsilon}_{li} - \bar{\hat{\varepsilon}}_l}{\sigma(\hat{\varepsilon}_{li})} \right|$$

- $\hat{\varepsilon}_i$ : résidu du pixel  $i$  de l'étiquette  $l$
- $\bar{\hat{\varepsilon}}_l$ : moyenne des résidus pour l'étiquette  $l$        $\text{MANE} \approx \text{z-score}$
- $\sigma(\hat{\varepsilon}_l)$ : écart-type pour les résidus de l'étiquette  $l$  dans le pixel  $i$
- $L_i$ : l'ensemble des étiquettes que nous avons dans le pixel  $i$

# Où les mesures du SIML sont-elles fiables ?



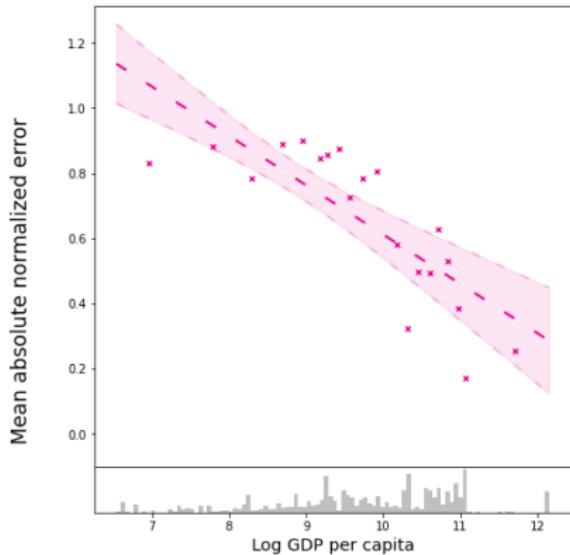
# Où les mesures du SIML sont-elles fiables ?



- MANE diffère de manière significative entre les continents :  $p < 0,01$
- Erreurs les plus faibles en Australie et en Afrique (déserts) et erreurs les plus élevées en Amérique du Nord et en Asie (zones urbaines et altitude élevée)
- Erreurs élevées dans les endroits extrêmes → erreur de mesure à inversion de la moyenne (fréquente en ML)

# Où les mesures du SIML sont-elles fiables ?

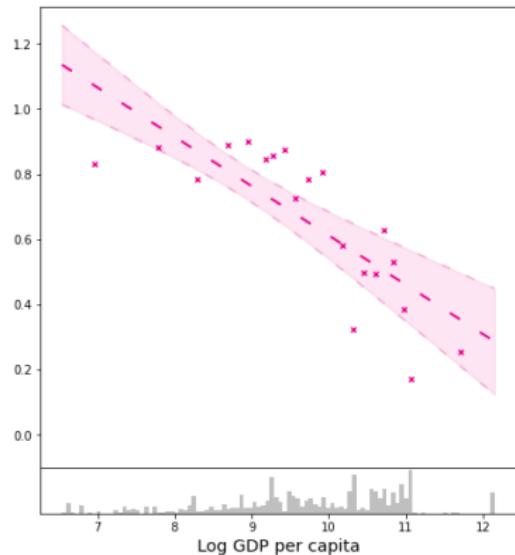
Exemple : L'agriculture



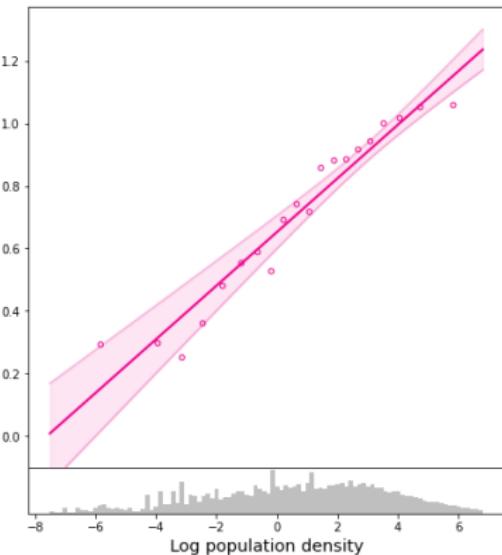
# Où les mesures du SIML sont-elles fiables ?

Exemple : L'agriculture

Mean absolute normalized error

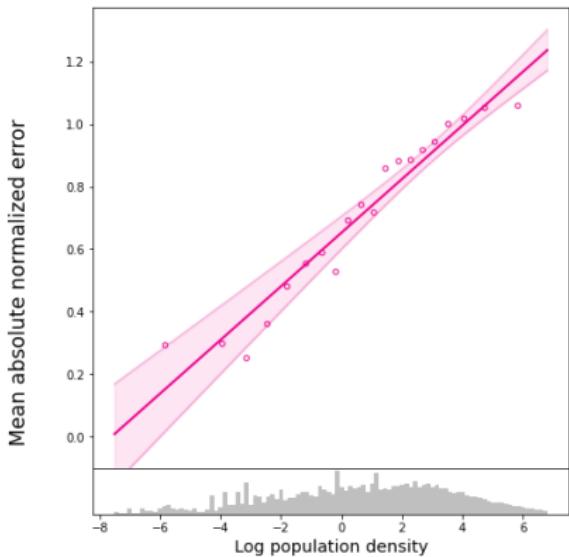
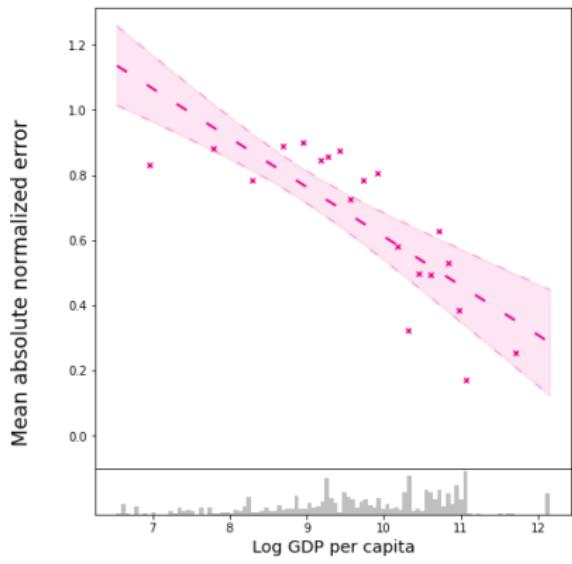


Mean absolute normalized error



# Où les mesures du SIML sont-elles fiables ?

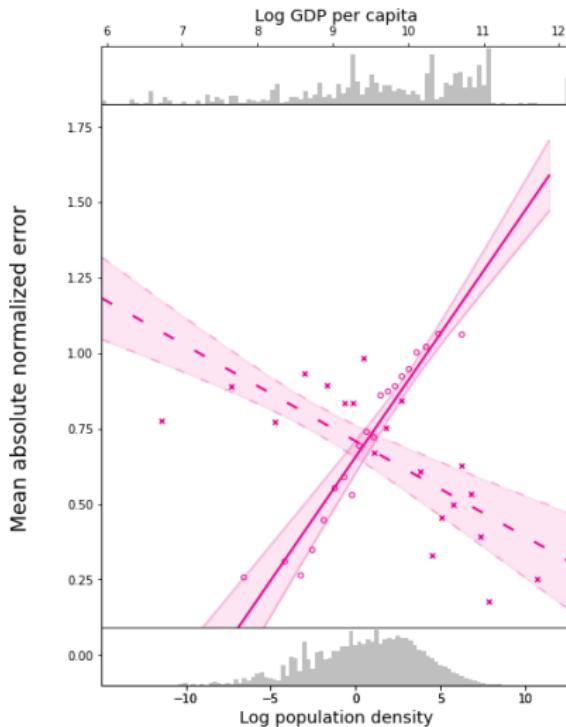
Exemple : L'agriculture



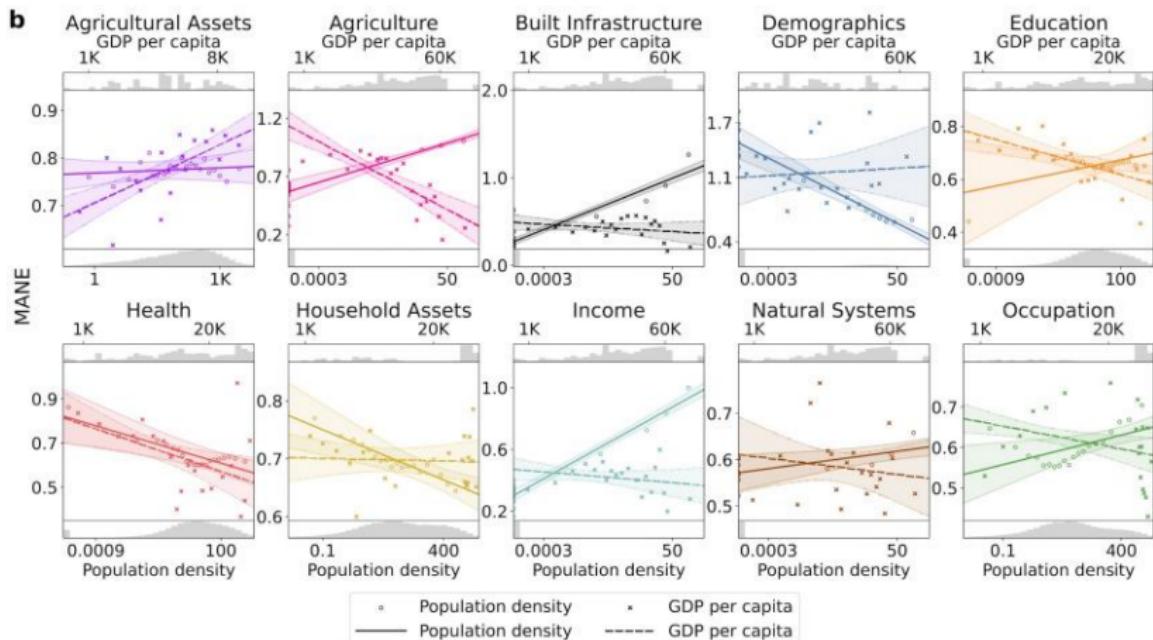
Assembliez le tout...

# Où les mesures du SIML sont-elles fiables ?

## Exemple : L'agriculture

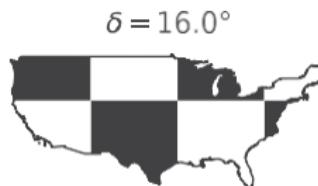
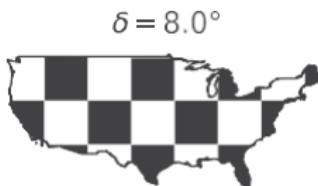
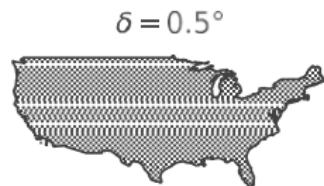


Où les mesures du SIML sont-elles fiables ?



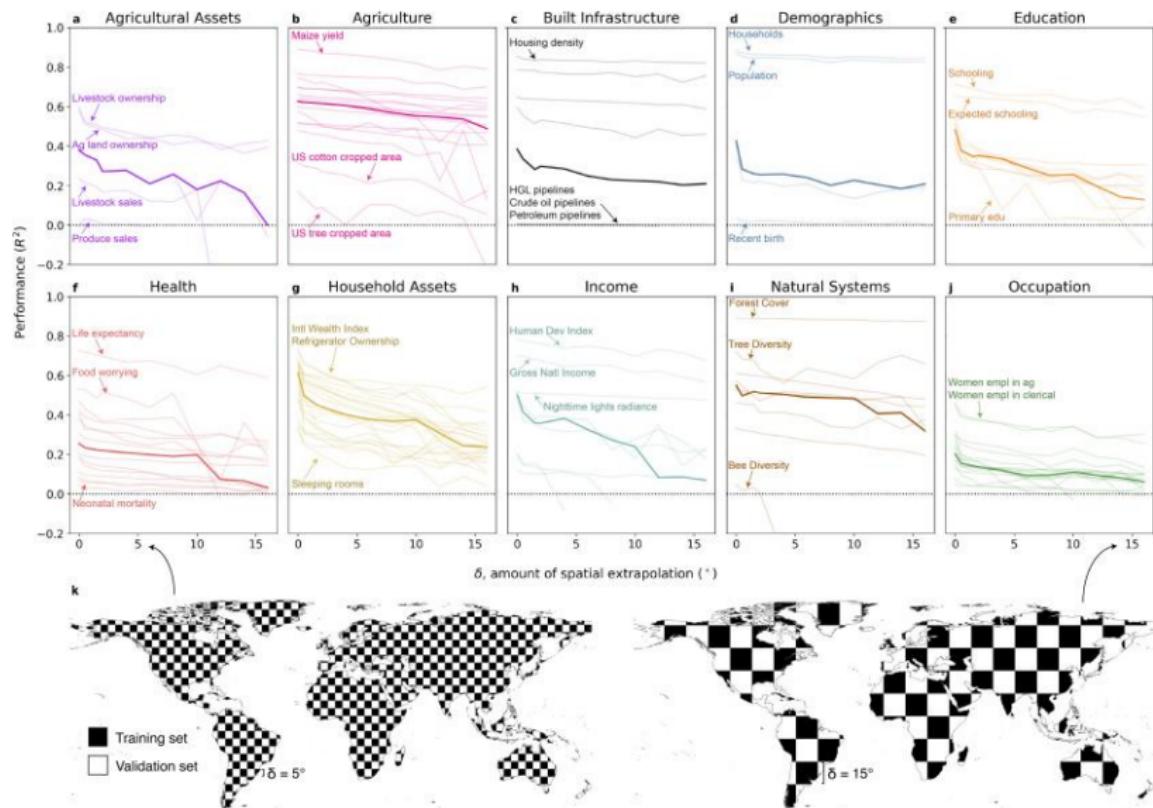
# Jusqu'où peut-on extrapoler à partir des données de formation ?

1. Échantillon de partition en damier
2. Apprentissage sur les carrés blancs
3. Test sur les carrés noirs
4. Mélanger les locations du damier & répéter
5. Comparer avec l'interpolation spatiale de la réalité du terrain



(Référence :  $8^\circ \times 8^\circ = 888 \text{ km} \times 682 \text{ km}$  (552 mi  $\times$  424 mi) au centroïde)

# Jusqu'où peut-on extrapoler à partir des données de formation ?



Nous utilisons les résultats de la validation croisée spatiale pour communiquer la qualité estimée des données parallèlement à la publication des prédictions globales

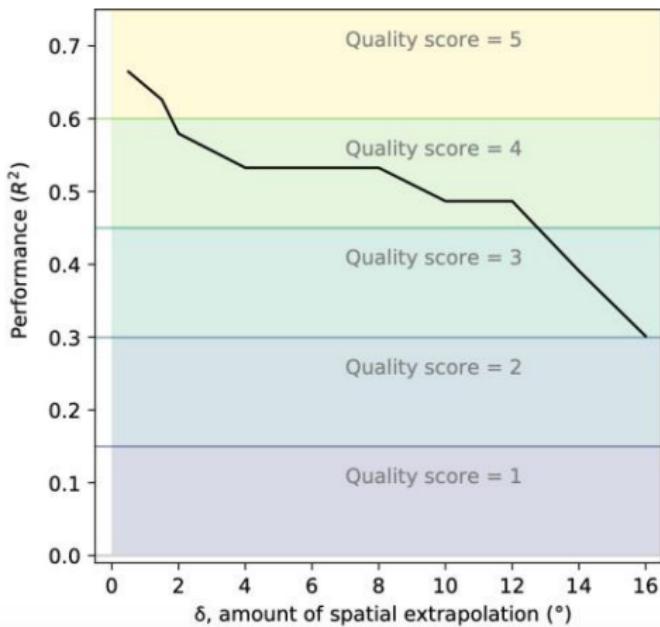
Pour chacun des 115 résultats :

1. Réaliser l'expérience de validation croisée spatiale (c'est-à-dire le "damier") décrite ci-dessus.
2. Déterminer une estimation de  $R^2$  pour tous les emplacements en dehors de l'ensemble d'apprentissage en fonction de la distance par rapport à l'observation de la vérité au sol la plus proche.
3. Attribuer à tous les lieux un score de qualité basé sur l'estimation de  $R^2$  : 0 ( $R^2 < 0$ ) → 5 ( $R^2 \geq 0.6$ )
4. Pour les résultats socio-économiques, masquer les zones peuplées

# Évaluer et communiquer l'incertitude

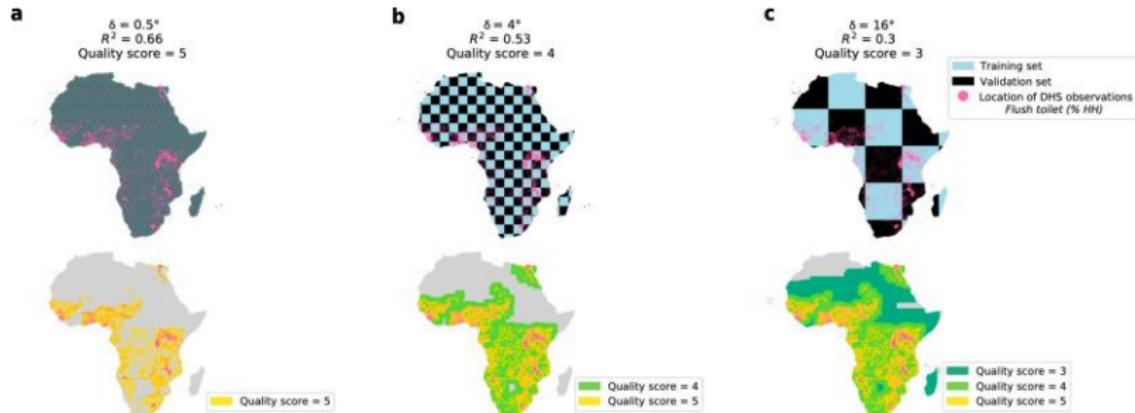
1. Réaliser l'expérience de validation croisée spatiale (c'est-à-dire le "damier") décrite précédemment.

Par exemple: l'accès à des toilettes à chasse d'eau :



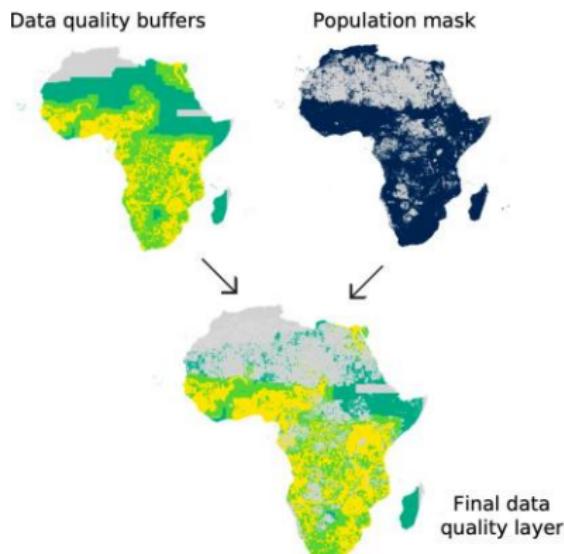
# Évaluer et communiquer l'incertitude

2. Déterminer une estimation de  $R^2$  pour tous les emplacements en dehors de l'ensemble d'apprentissage en fonction de la distance par rapport à l'observation de la vérité au sol la plus proche.
3. Attribuer à tous les lieux un score de qualité basé sur l'estimation de  $R^2$  : 0 ( $R^2 < 0$ ) → 5 ( $R^2 \geq 0.6$ )



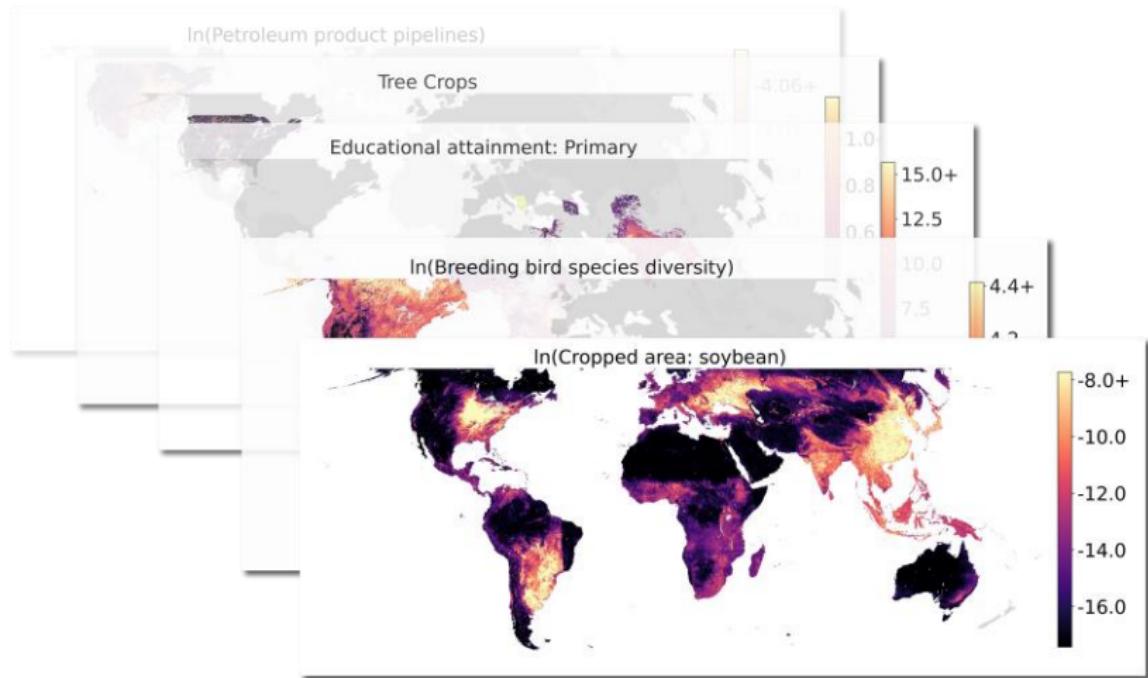
# Évaluer et communiquer l'incertitude

## 4. Pour les résultats socio-économiques, masquer les zones peuplées

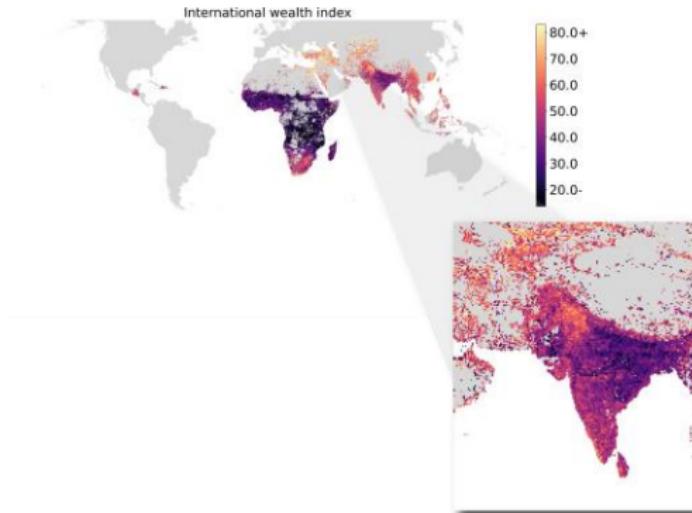


# Distribuer les prédictions et les couches de qualité des données

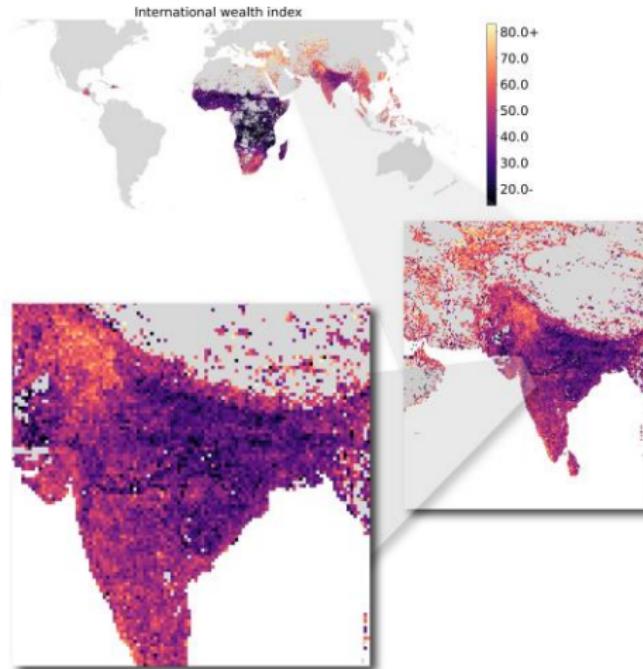
115 cartes



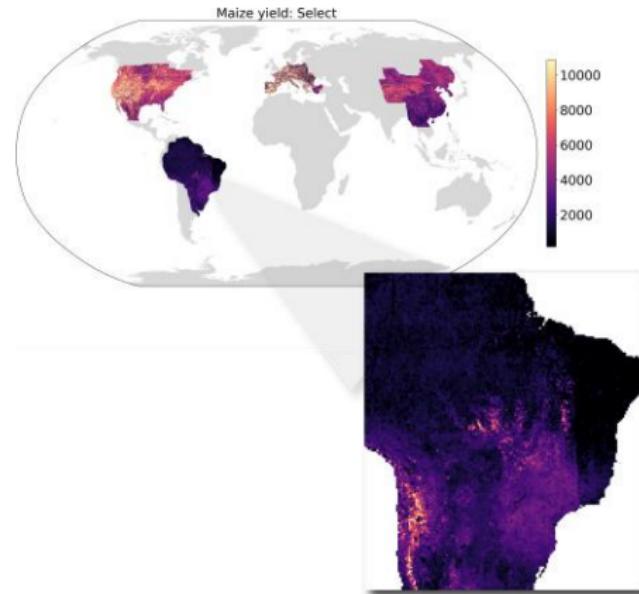
# Exemples de couches cartographiques



# Exemples de couches cartographiques

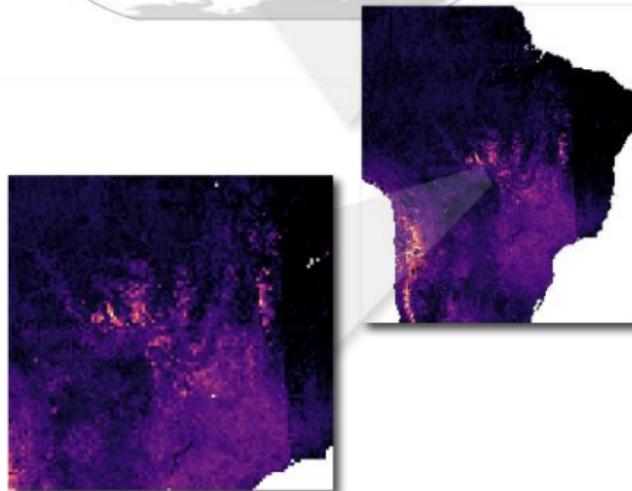
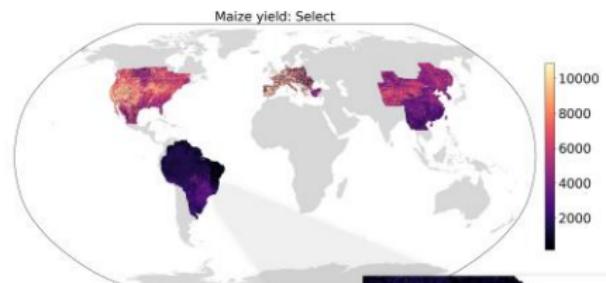


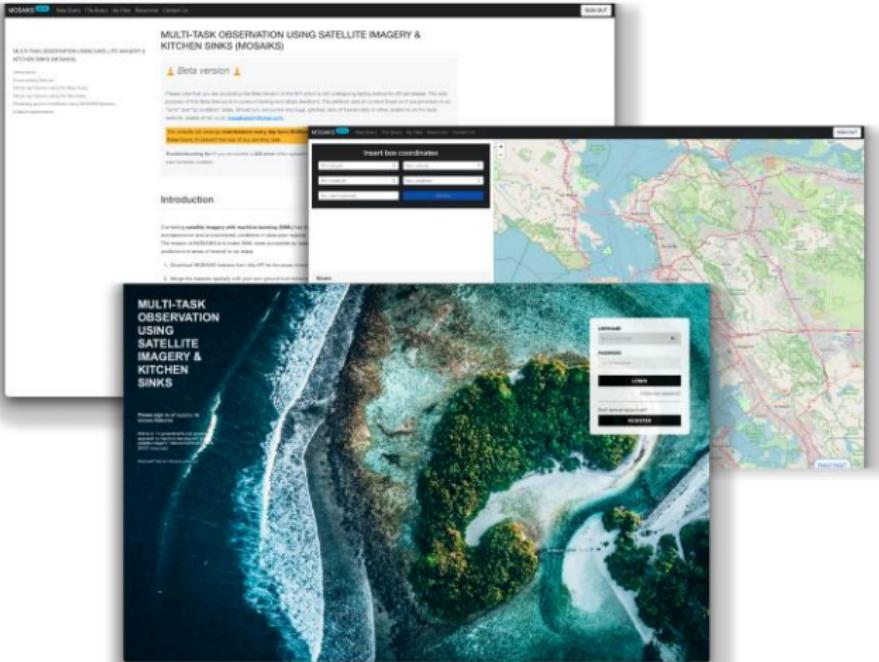
# Exemples de couches cartographiques



détails

# Exemples de couches cartographiques





# Aperçu

---

Méthodes

Résultats

Résumé

# Conclusions

---

1. Nous démontrons qu'il est possible de produire en masse des cartes mondiales à partir d'images satellite
  - >100 cartes prédites à l'aide d'une seule caractérisation de l'imagerie, à un faible coût de calcul
  - Le pipeline de réglage automatisé rend les prédictions basées sur l'imagerie "prêtes à l'emploi".

# Conclusions

---

1. Nous démontrons qu'il est possible de produire en masse des cartes mondiales à partir d'images satellite
  - >100 cartes prédictives à l'aide d'une seule caractérisation de l'imagerie, à un faible coût de calcul
  - Le pipeline de réglage automatisé rend les prédictions basées sur l'imagerie "prêtes à l'emploi".
2. Nous découvrons des modèles qui caractérisent la promesse de l'imagerie satellitaire pour la cartographie mondiale.
  - Observer les acteurs les plus performants (agriculture, biens des ménages, systèmes naturels) et les moins performants (santé, démographie).
  - Montrer la corrélation entre l'erreur de prédiction et le lieu, le revenu, la population

# Conclusions

1. Nous démontrons qu'il est possible de produire en masse des cartes mondiales à partir d'images satellite
  - >100 cartes prédictives à l'aide d'une seule caractérisation de l'imagerie, à un faible coût de calcul
  - Le pipeline de réglage automatisé rend les prédictions basées sur l'imagerie "prêtes à l'emploi".
2. Nous découvrons des modèles qui caractérisent la promesse de l'imagerie satellitaire pour la cartographie mondiale.
  - Observer les acteurs les plus performants (agriculture, biens des ménages, systèmes naturels) et les moins performants (santé, démographie).
  - Montrer la corrélation entre l'erreur de prédiction et le lieu, le revenu, la population
3. Nous publions les intrants, les résultats et les ressources de formation.
  - API : 4 000 fonctionnalités de Planet Labs, Inc. et de nombreuses ressources didactiques
  - Couche de qualité des données fournie avec les cartes prévisionnelles
  - Tous les codes et données d'entrée sont publics



# Remerciements

L'équipe

Benjamin Recht, Esther Rolf, Eugenio  
Noda, Hikari Murayama, Hannah  
Druckenmiller, Ian Bolliger, Jeanette Tseng,  
Jessica Katz, Jonathan Proctor, Luke  
Sherman, Miyabi Ishihara, Simon  
Greenhill, Solomon Hsiang, Tamma  
Carleton, Taryn Fransen, Trinetta Chong,  
Vaishaal Shankar

API MOSAIKS



Partenaires et financement

USAID, PNUD, CEGA, UCSB  
Bren

L'école : Étudiants en science  
des données

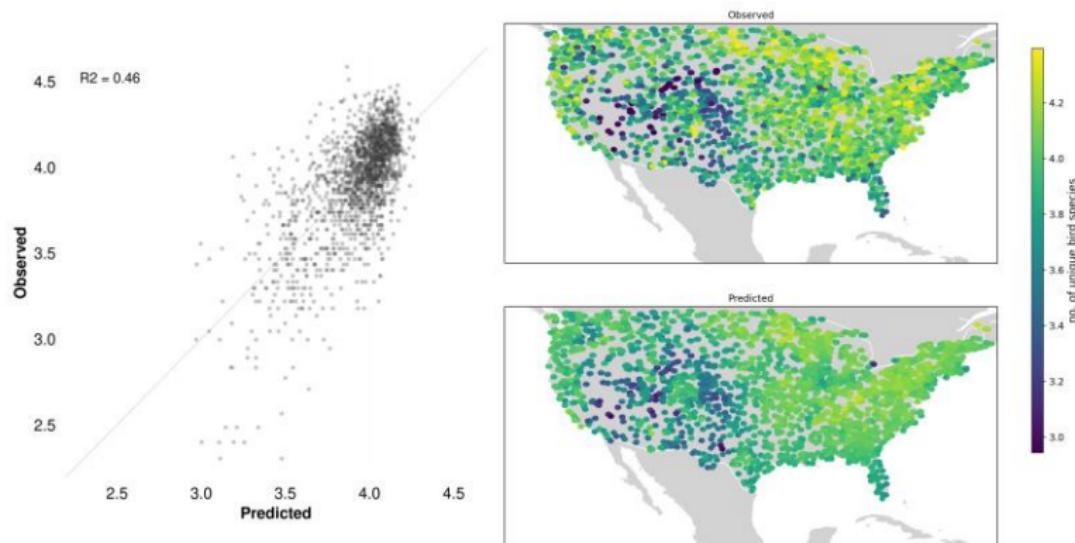
[www.mosaiks.org](http://www.mosaiks.org)

## Annexe

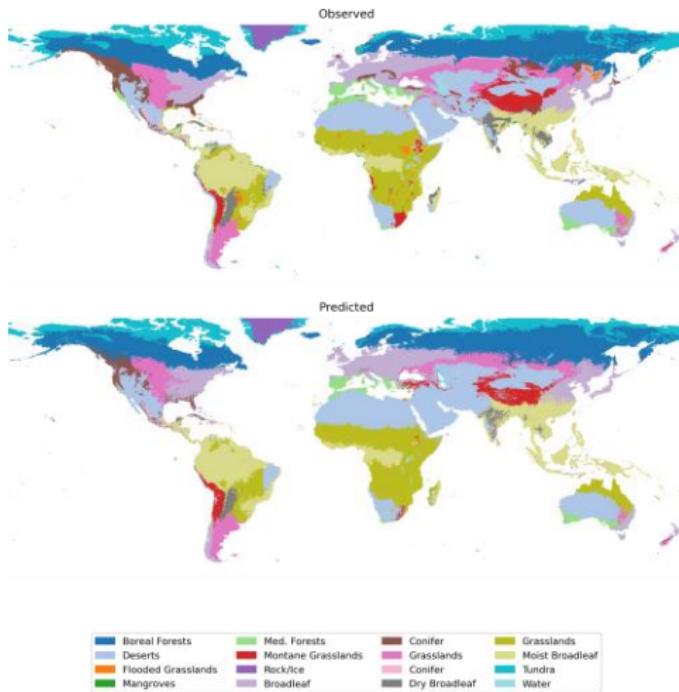
# Diversité des espèces d'oiseaux nicheurs

Source : U.S. Geological Survey : U.S. Geological Survey

Description : Nombre d'espèces uniques documentées par tous les segments de route



# Exemple de classificateur



# Performances testées et validées par croisement

